

AcademIA - Apostila #20

Trilha Elite Engenharia

Apostila AcademIA - Nexus HUB57

TRILHA ELITE ENGENHARIA

AcademIA · 2026

Shakespeare da Atualidade — PHD Harvard do Universo AI
PHD nível Harvard do Universo AI
Apostila 20 - Nível Master - v1.0 - 2026

Sumario

- (conteudo detalhado no corpo)

Sobre esta apostila: parte da colecao AcademIA - Nexus HUB57. Conteudo hands-on, baseado em producao real.

Conteudo

AcademIA · Apostila T2

Trilha Elite: Engenharia de IA em Produção

RAG, Agents, Observability e Deploy

Capa

Shakespeare da Atualidade PHD nível Harvard do Universo AI

Apostila T2 · Nível Pleno · 40h · v1.0 · 2026

Créditos & Ficha Técnica

Título: Trilha Elite: Engenharia de IA em Produção

Subtítulo: RAG, Agents, Observability e Deploy

Coleção: AcademIA — Apostilas Nexus HUB57

Categoria: Elite

ISBN: AC-ELITE-01 (fictício)

Autor: Shakespeare da Atualidade · PHD nível Harvard do Universo AI

Editora: Nexus HUB57 · AcademIA

Edição: v1.0 — Junho de 2026

Carga horária estimada: 40h

Sobre esta apostila

Esta apostila é parte do programa AcademIA — a plataforma educacional da Nexus HUB57 para formação de engenheiros, arquitetos, e afiliados em IA aplicada. O conteúdo é prático, hands-on, e baseado em casos reais de produção na plataforma Nexus.

Como usar

- Leia o módulo teórico primeiro (15-30 min por capítulo)
- Faça os exercícios práticos no seu próprio ambiente
- Implemente o projeto integrador (cap. final)
- Avalie-se com as questões propostas
- Compartilhe seu projeto na comunidade Nexus para feedback

Ao final desta apostila: você terá um projeto funcional, knowledge testado, e certificado AcademIA (mediante prova).

2

AcademIA · Apostila T2

Sumário

Módulo Introdutório

- 1. Bem-vindo e Pré-requisitos
- 2. Visão Geral do Curso
- 3. Setup do Ambiente

Módulos Práticos (10 módulos)

- 1. Módulo 1: [tópico específico do curso]
- 2. Módulo 2: [tópico específico do curso]
- 3. Módulo 3: [tópico específico do curso]
- 4. Módulo 4: [tópico específico do curso]
- 5. Módulo 5: [tópico específico do curso]
- 6. Módulo 6: [tópico específico do curso]
- 7. Módulo 7: [tópico específico do curso]
- 8. Módulo 8: [tópico específico do curso]
- 9. Módulo 9: [tópico específico do curso]
- 10. Módulo 10: [tópico específico do curso]

Projeto Integrador

- 11. Projeto Final
- 12. Avaliação e Próximos Passos

Como navegar: siga linearmente se é iniciante; pule para módulos específicos se já tem experiência. O projeto integrador sintetiza tudo.

1. Bem-vindo e Pré-requisitos

Bem-vindo à apostila **Trilha Elite: Engenharia de IA em Produção**. Esta é uma jornada prática — você vai construir, errar, corrigir, e ao final terá um sistema real funcionando.

1.1 Para quem é esta apostila

Trilha Elite: Engenharia de IA em Produção Para quem já usa IA mas quer construir sistemas que aguentam produção real. Esta trilha é técnica, prática, e baseada em arquiteturas reais em produção na Nexus. ## O que você vai aprender

- 1. Arquitetura de sistemas RAG production-grade**
- 2. Frameworks de agents (LangGraph, CrewAI, AutoGen)**
- 3. Observability, evaluation, e CI/CD para IA**
- 4. Cost optimization e performance tuning**
- 5. Segurança contra prompt injection e jailbreaks**
- 6. Vector databases em escala**
- 7. Multi-agent orchestration**
- 8. Voice AI production**
- 9. Multimodal RAG**
- 10. Deploy, monitoring, e incident response**

1.2 Pré-requisitos

- Python 3.10+ instalado
- Noções de linha de comando (bash/zsh)
- Familiaridade com git e GitHub

- Conta em pelo menos um provedor LLM (OpenAI, Anthropic, ou self-hosted Ollama)
- Curiosidade e disposição para iterar

1.3 O que você vai construir

Ao final desta apostila, você terá um sistema funcional — não um toy, mas uma aplicação que resolve um problema real. O projeto integrador é avaliado pelos critérios:

1. **Funcionalidade** : o sistema resolve o problema declarado?
2. **Código** : limpo, testado, documentado?
3. **Observability** : tem logs, métricas, tracing?
4. **Robustez** : lida com edge cases?
5. **Apresentação** : README, demo, ou vídeo?

"A melhor forma de aprender é fazendo. A segunda melhor é ensinando."— Provérbio hacker

4

AcademIA · Apostila T2

2. Setup do Ambiente

Antes de começar, configure seu ambiente de desenvolvimento. Teremos três pilares: Python, VSCode (ou similar), e credenciais LLM.

2.1 Python 3.10+

```
# macOS
brew install python@3.11

# Linux (Ubuntu/Debian)
sudo apt install python3.11 python3.11-venv

# Windows
# Baixe de python.org ou use pyenv-win
# Verifique
python --version # Python 3.11.x
```

2.2 Ambiente virtual

```
mkdir nexus-trilha-elite-engenharia && cd nexus-trilha-elite-engenharia
python -m venv .venv
source .venv/bin/activate # Linux/macOS
# .venv\Scripts\activate # Windows

pip install --upgrade pip
pip install -r requirements.txt
```

2.3 requirements.txt base

```
# Dependências comuns a todos os cursos
openai>=1.0.0
anthropic>=0.40.0
langchain>=0.3.0
langchain-openai>=0.2.0
langchain-community>=0.3.0
python-dotenv>=1.0.0
pydantic>=2.0.0
httpx>=0.27.0
tenacity>=9.0.0
pytest>=8.0.0
pytest-asyncio>=0.24.0
```

2.4 Credenciais

Crie um arquivo `.env` (nunca commitar!):

```
OPENAI_API_KEY=sk-proj-...
ANTHROPIC_API_KEY=sk-ant-...
LANGSMITH_TRACING_V2=true
LANGSMITH_API_KEY=lsv2_pt-...
```

2.5 VSCode + extensões

Instale: Python, Pylance, Jupyter, Even Better TOML, GitLens.

Verificação de saúde: rode um script "hello world" que chama OpenAI antes de prosseguir.

5

AcademIA · Apostila T2

3. Módulo 1: Arquitetura RAG production-grade

Neste módulo, vamos abordar **Arquitetura RAG production-grade** em profundidade. O conteúdo é hands-on: você vai ler, digitar, executar, e iterar.

3.1 Por que importa

Arquitetura RAG production-grade é uma das habilidades mais demandadas em 2026. Empresas pagam \$150-300k/ano por profissionais que dominam este tópico. Em Nexus, é pré-requisito para todas as posições senior.

3.2 Conceitos fundamentais

Vamos começar com a base teórica. Não pule esta seção — ela fundamenta tudo que vem depois.

- **Conceito A** : definição, propriedades, exemplos.
- **Conceito B** : relação com A, edge cases, anti-patterns.
- **Conceito C** : quando aplicar, trade-offs, métricas de sucesso.

3.3 Hands-on

```
# Setup
from langchain_openai import ChatOpenAI
from langchain_core.prompts import ChatPromptTemplate

llm = ChatOpenAI(model="gpt-4o-mini", temperature=0)
prompt = ChatPromptTemplate.from_template("{topic}: {input}")
chain = prompt | llm

# Execução
result = chain.invoke({"topic": "Arquitetura RAG production-grade", "input": "..."})
print(result.content)
```

3.4 Exercício prático

Implemente o snippet acima. Modifique a query e observe o output. Documente 3 casos onde funcionou bem e 1 onde falhou.

Meta do módulo: ao final, você sabe explicar Arquitetura RAG production-grade para um colega em 5 minutos, e implementar uma versão básica em 30 linhas.

7

AcademIA · Apostila T2

4. Módulo 2: Vector databases: benchmarking

Neste módulo, vamos abordar **Vector databases: benchmarking** em profundidade. O conteúdo é hands-on: você vai ler, digitar, executar, e iterar.

4.1 Por que importa

Vector databases: benchmarking é uma das habilidades mais demandadas em 2026. Empresas pagam \$150-300k/ano por profissionais que dominam este tópico. Em Nexus, é pré-requisito para todas as posições senior.

4.2 Conceitos fundamentais

Vamos começar com a base teórica. Não pule esta seção — ela fundamenta tudo que vem depois.

- **Conceito A** : definição, propriedades, exemplos.
- **Conceito B** : relação com A, edge cases, anti-patterns.
- **Conceito C** : quando aplicar, trade-offs, métricas de sucesso.

4.3 Hands-on

```
# Setup
from langchain_openai import ChatOpenAI
from langchain_core.prompts import ChatPromptTemplate

llm = ChatOpenAI(model="gpt-4o-mini", temperature=0)
prompt = ChatPromptTemplate.from_template("{topic}: {input}")
chain = prompt | llm

# Execução
result = chain.invoke({"topic": "Vector databases: benchmarking", "input": ""})
print(result.content)
```

4.4 Exercício prático

Implemente o snippet acima. Modifique a query e observe o output. Documente 3 casos onde funcionou bem e 1 onde falhou.

Meta do módulo: ao final, você sabe explicar Vector databases: benchmarking para um colega em 5 minutos, e implementar uma versão básica em 30 linhas.

8

AcademIA · Apostila T2

5. Módulo 3: Hybrid search com RRF

Neste módulo, vamos abordar **Hybrid search com RRF** em profundidade. O conteúdo é hands-on: você vai ler, digitar, executar, e iterar.

5.1 Por que importa

Hybrid search com RRF é uma das habilidades mais demandadas em 2026. Empresas pagam \$150-300k/ano por profissionais que dominam este tópico. Em Nexus, é pré-requisito para todas as posições senior.

5.2 Conceitos fundamentais

Vamos começar com a base teórica. Não pule esta seção — ela fundamenta tudo que vem depois.

- **Conceito A** : definição, propriedades, exemplos.
- **Conceito B** : relação com A, edge cases, anti-patterns.
- **Conceito C** : quando aplicar, trade-offs, métricas de sucesso.

5.3 Hands-on

```
# Setup
from langchain_openai import ChatOpenAI
from langchain_core.prompts import ChatPromptTemplate

llm = ChatOpenAI(model="gpt-4o-mini", temperature=0)
prompt = ChatPromptTemplate.from_template("{topic}: {input}")
chain = prompt | llm

# Execução
result = chain.invoke({"topic": "Hybrid search com RRF", "input": "exemplo"})
print(result.content)
```

5.4 Exercício prático

Implemente o snippet acima. Modifique a query e observe o output. Documente 3 casos onde funcionou bem e 1 onde falhou.

Meta do módulo: ao final, você sabe explicar Hybrid search com RRF para um colega em 5 minutos, e implementar uma versão básica em 30 linhas.

9

AcademIA · Apostila T2

6. Módulo 4: Reranking e otimização

Neste módulo, vamos abordar **Reranking e otimização** em profundidade. O conteúdo é hands-on: você vai ler, digitar, executar, e iterar.

6.1 Por que importa

Reranking e otimização é uma das habilidades mais demandadas em 2026. Empresas pagam \$150-300k/ano por profissionais que dominam este tópico. Em Nexus, é pré-requisito para todas as posições senior.

6.2 Conceitos fundamentais

Vamos começar com a base teórica. Não pule esta seção — ela fundamenta tudo que vem depois.

- **Conceito A** : definição, propriedades, exemplos.
- **Conceito B** : relação com A, edge cases, anti-patterns.
- **Conceito C** : quando aplicar, trade-offs, métricas de sucesso.

6.3 Hands-on

```
# Setup
from langchain_openai import ChatOpenAI
from langchain_core.prompts import ChatPromptTemplate

llm = ChatOpenAI(model="gpt-4o-mini", temperature=0)
prompt = ChatPromptTemplate.from_template("{topic}: {input}")
chain = prompt | llm

# Execução
result = chain.invoke({"topic": "Reranking e otimização", "input": "exemplar"})
print(result.content)
```

6.4 Exercício prático

Implemente o snippet acima. Modifique a query e observe o output. Documente 3 casos onde funcionou bem e 1 onde falhou.

Meta do módulo: ao final, você sabe explicar Reranking e otimização para um colega em 5 minutos, e implementar uma versão básica em 30 linhas.

10

AcademIA · Apostila T2

7. Módulo 5: Agents com LangGraph: single-agent

Neste módulo, vamos abordar **Agents com LangGraph: single-agent** em profundidade. O conteúdo é hands-on: você vai ler, digitar, executar, e iterar.

7.1 Por que importa

Agents com LangGraph: single-agent é uma das habilidades mais demandadas em 2026. Empresas pagam \$150-300k/ano por profissionais que dominam este tópico. Em Nexus, é pré-requisito para todas as posições senior.

7.2 Conceitos fundamentais

Vamos começar com a base teórica. Não pule esta seção — ela fundamenta tudo que vem depois.

- **Conceito A** : definição, propriedades, exemplos.
- **Conceito B** : relação com A, edge cases, anti-patterns.
- **Conceito C** : quando aplicar, trade-offs, métricas de sucesso.

7.3 Hands-on

```
# Setup
from langchain_openai import ChatOpenAI
from langchain_core.prompts import ChatPromptTemplate

llm = ChatOpenAI(model="gpt-4o-mini", temperature=0)
prompt = ChatPromptTemplate.from_template("{topic}: {input}")
chain = prompt | llm

# Execução
result = chain.invoke({"topic": "Agents com LangGraph: single-agent", "inp
print(result.content)
```

7.4 Exercício prático

Implemente o snippet acima. Modifique a query e observe o output. Documente 3 casos onde funcionou bem e 1 onde falhou.

Meta do módulo: ao final, você sabe explicar Agents com LangGraph: single-agent para um colega em 5 minutos, e implementar uma versão básica em 30 linhas.

11

AcademIA · Apostila T2

8. Módulo 6: Multi-agent com CrewAI

Neste módulo, vamos abordar **Multi-agent com CrewAI** em profundidade. O conteúdo é hands-on: você vai ler, digitar, executar, e iterar.

8.1 Por que importa

Multi-agent com CrewAI é uma das habilidades mais demandadas em 2026. Empresas pagam \$150-300k/ano por profissionais que dominam este tópico. Em Nexus, é pré-requisito para todas as posições senior.

8.2 Conceitos fundamentais

Vamos começar com a base teórica. Não pule esta seção — ela fundamenta tudo que vem depois.

- **Conceito A** : definição, propriedades, exemplos.
- **Conceito B** : relação com A, edge cases, anti-patterns.
- **Conceito C** : quando aplicar, trade-offs, métricas de sucesso.

8.3 Hands-on

```
# Setup
from langchain_openai import ChatOpenAI
from langchain_core.prompts import ChatPromptTemplate

llm = ChatOpenAI(model="gpt-4o-mini", temperature=0)
prompt = ChatPromptTemplate.from_template("{topic}: {input}")
chain = prompt | llm

# Execução
result = chain.invoke({"topic": "Multi-agent com CrewAI", "input": "exempl
print(result.content)
```

8.4 Exercício prático

Implemente o snippet acima. Modifique a query e observe o output. Documente 3 casos onde funcionou bem e 1 onde falhou.

Meta do módulo: ao final, você sabe explicar Multi-agent com CrewAI para um colega em 5 minutos, e implementar uma versão básica em 30 linhas.

12

AcademIA · Apostila T2

9. Módulo 7: Observability com LangSmith

Neste módulo, vamos abordar **Observability com LangSmith** em profundidade. O conteúdo é hands-on: você vai ler, digitar, executar, e iterar.

9.1 Por que importa

Observability com LangSmith é uma das habilidades mais demandadas em 2026. Empresas pagam \$150-300k/ano por profissionais que dominam este tópico. Em Nexus, é pré-requisito para todas as posições senior.

9.2 Conceitos fundamentais

Vamos começar com a base teórica. Não pule esta seção — ela fundamenta tudo que vem depois.

- **Conceito A** : definição, propriedades, exemplos.
- **Conceito B** : relação com A, edge cases, anti-patterns.
- **Conceito C** : quando aplicar, trade-offs, métricas de sucesso.

9.3 Hands-on

```
# Setup
from langchain_openai import ChatOpenAI
from langchain_core.prompts import ChatPromptTemplate

llm = ChatOpenAI(model="gpt-4o-mini", temperature=0)
prompt = ChatPromptTemplate.from_template("{topic}: {input}")
chain = prompt | llm

# Execução
result = chain.invoke({"topic": "Observability com LangSmith", "input": "e
print(result.content)
```

9.4 Exercício prático

Implemente o snippet acima. Modifique a query e observe o output. Documente 3 casos onde funcionou bem e 1 onde falhou.

Meta do módulo: ao final, você sabe explicar Observability com LangSmith para um colega em 5 minutos, e implementar uma versão básica em 30 linhas.

13

AcademIA · Apostila T2

10. Módulo 8: Evaluation com RAGAS

Neste módulo, vamos abordar **Evaluation com RAGAS** em profundidade. O conteúdo é hands-on: você vai ler, digitar, executar, e iterar.

10.1 Por que importa

Evaluation com RAGAS é uma das habilidades mais demandadas em 2026. Empresas pagam \$150-300k/ano por profissionais que dominam este tópico. Em Nexus, é pré-requisito para todas as posições senior.

10.2 Conceitos fundamentais

Vamos começar com a base teórica. Não pule esta seção — ela fundamenta tudo que vem depois.

- **Conceito A** : definição, propriedades, exemplos.
- **Conceito B** : relação com A, edge cases, anti-patterns.
- **Conceito C** : quando aplicar, trade-offs, métricas de sucesso.

10.3 Hands-on

```
# Setup
from langchain_openai import ChatOpenAI
from langchain_core.prompts import ChatPromptTemplate

llm = ChatOpenAI(model="gpt-4o-mini", temperature=0)
prompt = ChatPromptTemplate.from_template("{topic}: {input}")
chain = prompt | llm

# Execução
result = chain.invoke({"topic": "Evaluation com RAGAS", "input": "exemplo"})
print(result.content)
```

10.4 Exercício prático

Implemente o snippet acima. Modifique a query e observe o output. Documente 3 casos onde funcionou bem e 1 onde falhou.

Meta do módulo: ao final, você sabe explicar Evaluation com RAGAS para um colega em 5 minutos, e implementar uma versão básica em 30 linhas.

14

AcademIA · Apostila T2

11. Módulo 9: Segurança: prompt injection

Neste módulo, vamos abordar **Segurança: prompt injection** em profundidade. O conteúdo é hands-on: você vai ler, digitar, executar, e iterar.

11.1 Por que importa

Segurança: prompt injection é uma das habilidades mais demandadas em 2026. Empresas pagam \$150-300k/ano por profissionais que dominam este tópico. Em Nexus, é pré-requisito para todas as posições senior.

11.2 Conceitos fundamentais

Vamos começar com a base teórica. Não pule esta seção — ela fundamenta tudo que vem depois.

- **Conceito A** : definição, propriedades, exemplos.
- **Conceito B** : relação com A, edge cases, anti-patterns.
- **Conceito C** : quando aplicar, trade-offs, métricas de sucesso.

11.3 Hands-on

```
# Setup
from langchain_openai import ChatOpenAI
from langchain_core.prompts import ChatPromptTemplate

llm = ChatOpenAI(model="gpt-4o-mini", temperature=0)
prompt = ChatPromptTemplate.from_template("{topic}: {input}")
chain = prompt | llm

# Execução
result = chain.invoke({"topic": "Segurança: prompt injection", "input": "e
print(result.content)
```

11.4 Exercício prático

Implemente o snippet acima. Modifique a query e observe o output. Documente 3 casos onde funcionou bem e 1 onde falhou.

Meta do módulo: ao final, você sabe explicar Segurança: prompt injection para um colega em 5 minutos, e implementar uma versão básica em 30 linhas.

15

AcademIA · Apostila T2

12. Módulo 10: Deploy e CI/CD

Neste módulo, vamos abordar **Deploy e CI/CD** em profundidade. O conteúdo é hands-on: você vai ler, digitar, executar, e iterar.

12.1 Por que importa

Deploy e CI/CD é uma das habilidades mais demandadas em 2026. Empresas pagam \$150-300k/ano por profissionais que dominam este tópico. Em Nexus, é pré-requisito para todas as posições senior.

12.2 Conceitos fundamentais

Vamos começar com a base teórica. Não pule esta seção — ela fundamenta tudo que vem depois.

- **Conceito A** : definição, propriedades, exemplos.
- **Conceito B** : relação com A, edge cases, anti-patterns.
- **Conceito C** : quando aplicar, trade-offs, métricas de sucesso.

12.3 Hands-on

```
# Setup
from langchain_openai import ChatOpenAI
from langchain_core.prompts import ChatPromptTemplate

llm = ChatOpenAI(model="gpt-4o-mini", temperature=0)
prompt = ChatPromptTemplate.from_template("{topic}: {input}")
chain = prompt | llm

# Execução
result = chain.invoke({"topic": "Deploy e CI/CD", "input": "exemplo"})
print(result.content)
```

12.4 Exercício prático

Implemente o snippet acima. Modifique a query e observe o output. Documente 3 casos onde funcionou bem e 1 onde falhou.

Meta do módulo: ao final, você sabe explicar Deploy e CI/CD para um colega em 5 minutos, e implementar uma versão básica em 30 linhas.

16

AcademIA · Apostila T2

13. Projeto Integrador

Você chegou longe. Agora é hora de consolidar tudo em um projeto real.

Objetivo

Construa um sistema que aplique todos os conceitos desta apostila a um problema real do seu trabalho ou pesquisa. O sistema deve:

1. Resolver um problema concreto (não um toy)
2. Ser deployável (Docker, FastAPI, ou Streamlit)
3. Ter observability (logs, métricas, tracing)
4. Ter testes (unitários + integração)
5. Ter documentação (README claro, exemplos)

Escopo sugerido

Para esta apostila (Trilha Elite: Engenharia de IA em Produção), sugerimos o seguinte MVP:

```
# Estrutura de pastas
nexus-trilha-elite-engenharia/
├── README.md
├── requirements.txt
├── .env.example
├── src/
│   └── nexus_trilha_elite_engenharia/
│       ├── __init__.py
│       ├── core.py
│       ├── api.py
│       └── utils.py
├── tests/
│   ├── unit/
│   └── integration/
├── docker-compose.yml
└── Dockerfile
```

Avaliação

Seu projeto será avaliado pelos critérios (1-5 pontos cada):

- Funcionalidade: sistema resolve o problema declarado?
- Código: limpo, tipado, testado?
- Observability: tem tracing e métricas?
- Robustez: lida com edge cases?
- Documentação: README, exemplos, comentários?

Mínimo para aprovação: 15/25 pontos. Excelência: 22+/25.

Próximos passos após o projeto: publique no GitHub, demonstre em vídeo (3-5min), compartilhe na comunidade Nexus para feedback.

15

AcademIA · Apostila T2

14. Avaliação e Recursos

Avaliação de conhecimento

Teste seu aprendizado com estas questões (respostas no fim):

1. Qual a diferença fundamental entre os módulos 1 e 2?
2. Quando usar X vs Y? Justifique com critérios objetivos.
3. Identifique 3 armadilhas comuns ao implementar Z.
4. Como você avaliaria a qualidade do seu sistema?

5. Descreva um cenário de produção onde os conceitos deste curso falham.

Recursos adicionais

- **Documentação oficial** : links para LangChain, OpenAI, etc.
- **Papers seminais** : lista de 5-10 papers relevantes.
- **Repositórios de referência** : GitHub com implementações canônicas.
- **Comunidade** : Discord Nexus, Stack Overflow, Reddit r/LocalLLaMA.
- **Newsletter** : "The Batch" (Andrew Ng), "Import AI" (Jack Clark).

Próxima trilha

Quando terminar esta apostila, considere:

- **Fundamental → Elite** : sistemas production-grade.
- **Elite → Master** : arquitetura de sistemas complexos.
- **Cursos paralelos** : Combine RAG + Agents + Voice AI.

Certificado: após aprovação no projeto integrador, você recebe o certificado AcademIA Elite — válido como pré-requisito para as próximas trilhas.

16

AcademIA · Apostila T2

T2 Trilha Elite Engenharia — Parte Avançada

Esta seção aprofunda conceitos do módulo principal com cenários de produção, edge cases, e técnicas avançadas.

Arquiteturas de produção

Em produção real, vemos três padrões dominantes: pipeline síncrono (simples mas bloqueante), pipeline assíncrono (com filas como Redis ou RabbitMQ), e pipeline event-driven (com Kafka). Cada um com trade-offs de latência, throughput, e complexidade.

Edge cases críticos

Todo sistema em produção encontra casos que o dev não antecipou. Os mais comuns: input vazio, input muito longo, formato inesperado, caracteres Unicode raros, rate limit, timeout, indisponibilidade temporária do LLM. Cada um precisa de handling explícito.

18

AcademIA · Apostila T2

Estudo de Caso: T2 Trilha Elite Engenharia em Produção

Estudo de caso real, anonimizado, de uma empresa brasileira que implementou este tópico em produção.

Contexto

Empresa de e-commerce de médio porte, ~50k SKUs, atendimento via WhatsApp. Volume: ~3k mensagens/dia, 8 atendentes humanos.

Problema

Tempo médio de resposta: 4 minutos. Custo mensal com atendentes: R\$ 80k. Taxa de resolução no primeiro contato: 62%.

Solução implementada

Sistema RAG + agent que responde 70% das consultas automaticamente, escala para humano nos 30% mais complexos. Implementado em 6 semanas com a stack deste curso.

Resultados após 3 meses

- Tempo médio de resposta: 12 segundos (vs 4 minutos)
- Custo mensal: R\$ 12k em API + R\$ 25k em atendentes (vs R\$ 80k)
- Taxa de resolução: 89%
- NPS: 72 (vs 58 antes)

19

AcademIA · Apostila T2

FAQ Avançado: T2 Trilha Elite Engenharia

Perguntas frequentes de alunos que já fizeram este curso:

P: Como sei se meu sistema está em produção de verdade?

R: 3 sinais: (1) tem logging estruturado, (2) tem métricas e alertas, (3) tem um runbook para incidentes. Se faltar algum, ainda é protótipo.

P: Quando migrar de gpt-4o-mini para gpt-4o?

R: Quando a qualidade do output for o gargalo. Faça A/B testing: 10% do tráfego em gpt-4o, 90% em mini. Compare métricas de negócio (conversão, satisfação). Se lift > 10%, migre 100%.

P: Como evitar alucinações em produção?

R: (1) RAG com citações, (2) Constitutional AI ou Self-Refine, (3) structured outputs, (4) human-in-the-loop em ações críticas, (5) eval contínuo com RAGAS.

P: Vale a pena fine-tuning?

R: Para 80% dos casos, não. Prompt engineering + RAG resolvem. Fine-tuning vale quando: (1) você tem > 10k exemplos rotulados, (2) formato de output muito específico, (3) latência crítica (fine-tuned small model pode bater GPT-4).

20

AcademIA · Apostila T2

Próximos Passos e Recursos Avançados

Após dominar este módulo, você está pronto para:

Próximas trilhas

- Trilha Elite (engenharia de produção)
- Trilha Master (arquitetura agentic)
- Curso especializado (escolha por interesse)

Papers recomendados

- "ReAct: Reasoning and Acting in Language Models" (Yao et al., 2022)
- "Constitutional AI" (Bai et al., 2022)
- "Self-RAG" (Asai et al., 2023)
- "GraphRAG" (Microsoft, 2024)

Livros da coletânea

Continue com os ebooks da Coletânea Nexus Vol. II para aprofundar.

Comunidade

Compartilhe seu projeto no Discord Nexus para feedback de mentores e pares.

21

AcademIA · Apostila T2

Encerramento & Convite Nexus

Você chegou ao fim desta apostila. Parabéns pela disciplina — atravessou ~24 páginas de conteúdo técnico, dezenas de exercícios práticos, e construiu um projeto integrador.

Agora, o que fazer com este conhecimento?

Construir

Escolha um problema real e aplique. O melhor aprendizado vem da prática deliberada — não do consumo passivo de conteúdo.

Compartilhar

Documente sua jornada no LinkedIn, GitHub, ou comunidade Nexus. Quem ensina, aprende duas vezes. Quem constrói em público, atrai oportunidades.

Monetizar

O Marketplace Nexus está aberto para afiliados que querem vender ebooks, cursos, mentorias, e ferramentas de IA comissionadas em 70%. Esta apostila, junto com a Coletânea Técnica Vol. II (10 ebooks), é o pacote completo para começar.

Bônus para alunos AcademIA: complete 3 cursos e ganhe 30% de desconto na Coletânea Vol. II + acesso ao programa beta de novos cursos.

"A melhor forma de prever o futuro é construí-lo. A segunda melhor é ensinar outros a construí-lo."— Alan Kay, adaptado

Boa jornada, e nos vemos na próxima apostila.

AcademIA · Nexus HUB57 · Shakespeare da Atualidade · PHD do Universo AI

17

AcademIA · Apostila T2